

# Mutua informazione, secondo teorema di Shannon del canale rumoroso e sua dimostrazione

Luca Barbieri<sup>1</sup>

<sup>1</sup>mat  : minicorso entropie

## Abstract

Viene approfondito il Secondo Teorema di Shannon del canale rumoroso: prima vengono date le definizioni necessarie per comprendere il teorema, viene enunciato il teorema e dimostrato, viene poi fatto un esempio con una piccola rete neurale implementata con pythorc per il riconoscimento di numeri scritti a mano del database MNIST. Viene analizzato ogni passaggio della trasmissione di un segnale (il riconoscimento di una cifra scritta a mano) attraverso un canale rumoroso dal punto di vista della teoria dell'informazione, il codice completo si trova [QUI](#)

## 1 Definizioni

### 1.1 Entropia e Capacità

Nel 1948 Claude Shannon introdusse la definizione di entropia per una distribuzione di probabilità discreta  $P$ :

$$S[P] = - \langle \log(P) \rangle = - \sum_{n=1}^N P_n \log(P_n) \quad (1)$$

che definisce il valor medio di *informazione*, quantificata con  $\log(P)$ , trasmessa fra due agenti a conoscenza della distribuzione  $P$  con cui sono generati gli eventi trasmessi.

Data questa definizione è naturale definire anche la *capacità* di un canale come l'entropia massima dei segnali generati da una sorgente con distribuzione  $P$  trasmessi attraverso il canale.

### 1.2 Codifica

Codificare un messaggio significa comprimerlo, ridurre il numero di bit al secondo necessari per la sua trasmissione attraverso un canale. Normalmente quando trasmettiamo un messaggio, stiamo trasmettendo qualcosa che ha un significato ben preciso in una lingua predeterminata fra noi e il ricevente. Se sia il trasmittente che il ricevente sono a conoscenza della distribuzione di probabilità che genera il messaggio, possono codificarlo, assegnare cioè ad ogni elemento (lettera, parola, cifra, bit...) un altro elemento (un numero ad esempio) in modo da rendere più efficace e soprattutto meno dispendiosa la trasmissione. Affinchè il ricevente sia in grado di *decodificare* il messaggio non ci devono essere ambiguità, la corrispondenza fra gli elementi del messaggio originario e quelli del codice deve essere biunivoca: risulta chiaro quindi che la codifica non è altro che una funzione invertibile.

### 1.3 Rumore

Qualora ad ogni comunicazione dello stesso messaggio dovessero verificarsi errori diversi ci troveremmo in presenza di *rumore*, quello che qui abbiamo chiamato "errore" nella trasmissione di un messaggio si traduce nella corruzione di un numero  $n$  di bit; al processo stocastico di generazione del messaggio dalla distribuzione

$P$  va quindi aggiunto quello del rumore che avviene durante la trasmissione e all'informazione che dobbiamo estrarre dal messaggio dobbiamo aggiungere quella necessaria a correggere il numero di bit corrotti dal rumore per poter risalire al messaggio originario.

### 1.4 Ambiguità

Nel caso di trasmissione affetta da rumore (il caso reale) abbiamo bisogno di quantificare l'informazione perduta nel processo di trasmissione. Quanto del segnale di input  $X$  è andato perduto (e quindi è differente nel segnale di output  $Y$ )? L'ambiguità è la risposta a questa domanda: essa è definita come l'entropia della sorgente condizionata al segnale ricevuto  $S[P^{(X|Y)}]$ . In presenza di rumore definiamo quindi il tasso reale di informazione effettivamente trasmessa tramite la *mutua entropia*:

$$R \equiv S^{(m)}[P^{(X)}, P^{(Y)}] = S[P^{(X)}] - S[P^{(X|Y)}] \quad (2)$$

Dalla formula appare chiaro che essa non è altro che l'entropia nel caso ideale privo di rumore meno l'ambiguità causata dal rumore.

## 2 Secondo Teorema di Shannon

Se la trasmissione di un messaggio (informazione) è affetta da rumore.

### 2.1 Enunciato

Dati un canale di trasmissione di capacità  $C$  e una sorgente di entropia  $S_X$ :

1. Se  $S_X \leq C$ , esiste sempre una codifica tale che il segnale  $X$  della sorgente possa essere trasmesso lungo il canale con un'ambiguità arbitrariamente piccola.
2. Se  $S_X > C$  esiste una codifica del segnale tale che l'ambiguità  $S_{(X|Y)}$  della trasmissione sia minore di  $S_X - C + \epsilon$ , con  $\epsilon > 0$  piccolo a piacere.
3. Non esiste alcuna codifica che dia un'ambiguità  $S_{(X|Y)}$  strettamente minore di  $S_X - C$

Personalmente ho trovato molto intuitiva l'immagine riportata sotto, presa da [\[1\]](#)




Figure 1: Secondo teorema di Shannon in breve

## 2.2 Dimostrazione

Il teorema viene dimostrato dimostrando separatamente le tre parti:

### 2.2.1 Dimostrazione prima parte

Al fine di dimostrare l'esistenza di *almeno una* codifica tale che il segnale venga trasmesso con un'ambiguità arbitrariamente piccola vogliamo calcolare il valore aspettato del numero di bit sbagliati mediando su tante codifiche di sorgenti diverse, trovando che è minore di un certo valore  $\varepsilon$  piccolo a piacere.

Per prima cosa prendiamo in considerazione una sorgente che abbia entropia mutua uguale (a meno di  $\delta$  piccoli nel limite di lunghi segnali) alla capacità  $C$  del canale; una sorgente di questo tipo ha una distribuzione di segnale di input detta *distribuzione ottimale di input*  $P_{opt}^{(X)}$ . Il primo teorema di Shannon, detto *Teorema della codifica della sorgente* ci dice che l'informazione media in un numero di bit trasmessa in input (per le sequenze di lunghezza  $L$ ) è pari a  $LS_X$ . L'insieme delle sequenze tipiche in input e output saranno composte circa da  $2^{LS_i}$ ,  $i = X, Y$  elementi quindi ogni sorgente tipica di output può essere prodotta da circa  $2^{LS_{X|Y}}$  input diversi.

Come seconda cosa prendiamo in considerazione una sorgente generica  $X'$  che ha tasso medio di informazione prodotta  $R$  minore della capacità del canale, la cui distribuzione dei segnali di input sarà quindi un generico  $P^{(X')}$ .

Ora un output  $y^*$  qualsiasi sicuramente è stato generato da uno specifico input ma essendo corrotto dal rumore manca la certezza e vari altri input potrebbero averlo generato; ci interessa calcolare la probabilità che più di un input generi  $y^*$ . Attraverso il canale disturbato vengono trasmessi  $2^{LR}$  messaggi, la probabilità che un possibile input tipico non sia un messaggio effettivamente trasmesso sarà quindi  $1 - 2^{L(R-S_X)}$ , il numero di messaggi corrotti a causa del rumore del canale è  $2^{LS_{X|Y}}$ , la probabilità che nessuno di questi corrisponda a un messaggio reale di input è:

$$p_0 \equiv [1 - 2^{L(R-S_X)}]^{2^{LS_{X|Y}}} \quad (3)$$

Dato che  $R < C \equiv S_X - S_{X|Y} \Rightarrow R - C = R - S_X + S_{X|Y} = -\eta$ , abbiamo:

$$p_0 \equiv \left[1 - \frac{2^{-L\eta}}{2^{LS_{X|Y}}}\right] \simeq 1 - \frac{2^{-L\eta}}{2^{LS_{X|Y}}} 2^{LS_{X|Y}} = 1 - 2^{-L\eta} \rightarrow 1, L \rightarrow \infty \quad (4)$$

Dalla relazione scritta sopra ricaviamo che per segnali grandi la probabilità che non ci siano altri input responsabili di un dato output tende a 1 (l'evento è certo) e l'ambiguità scompare, su un insieme aleatorio di codifiche la probabilità media di errore di trasmissione tende a zero, per quanto discusso all'inizio esiste quindi *almeno una* codifica la cui probabilità di errore tende a zero.

### 2.2.2 Dimostrazione seconda parte

Nel caso i cui la nostra sorgente avesse entropia  $S'_X > C$  trasmettiamo  $C$  bit per simbolo, perdendo l'informazione  $S'_X - C$ . In questo caso quindi l'ambiguità si riduce a:

$$S_{X'|Y} = S'_X - C + \varepsilon \quad (5)$$

(con  $\varepsilon$  chiaramente piccolo a piacere).

### 2.2.3 Dimostrazione terza parte

La dimostrazione della terza parte del teorema si svolge per assurdo.

Una codifica di sorgente  $X'' = \mathcal{M}$  che abbia entropia  $S_{X''} > C$  che generi però un'ambiguità più bassa di  $S_{X''} - C$ , diciamo pari a  $S_{X''} - C - \Delta$ . Il tasso di produzione di informazione varrebbe quindi:

$$R \equiv S_{X''} - S_{X''|Y} = C + \Delta \quad (6)$$

In questo caso però  $R > C$ , in contraddizione con la definizione di capacità.

Il teorema è quindi dimostrato.

## 3 Riconoscimento di cifre scritte a mano come trasmissione di informazione


Il compito forse più banale che può svolgere una CNN (rete neurale convoluzionale, specializzata nel riconoscimento delle immagini) è quello di riconoscere cifre scritte a mano, è stato uno dei primi esperimenti messi a punto a questo scopo ed è uno dei primi esercizi che si svolgono tutt'oggi quando ci si avvicina alla materia.

Il riconoscimento da parte di una rete neurale di una singola cifra scritta a mano rappresenta a tutti gli effetti la trasmissione di informazione attraverso un canale, ho quindi implementato una rete neurale per il riconoscimento del dataset MNIST e, come esempio, l'ho testata per il riconoscimento di 9 cifre (i numeri da 0 a 9 opportunamente corrotti con del rumore aleatorio per simulare un canale rumoroso), implementando il calcolo dell'entropia di Shannon per ogni sorgente per poter commentare le prestazioni della rete dal punto di vista della teoria dell'informazione: il codice Colab commentato si trova su GitHub a questo link: [https://github.com/daltonismo15/Retina-MNIST-entropia-di-Shannon/blob/main/Retina\\_MNIST\\_entropia\\_di\\_Shannon.ipynb](https://github.com/daltonismo15/Retina-MNIST-entropia-di-Shannon/blob/main/Retina_MNIST_entropia_di_Shannon.ipynb)


Nel nostro esempio il trasmittente è colui che scrive il numero a mano e il ricevente legge solo il risultato fornitogli dalla CNN.

La rete è ben funzionante e ben addestrata: alla fine del ciclo di training la Loss è dell'ordine di  $10^{-3}$ .

Per avere dei risultati significativi aggiungo "manualmente" del rumore al messaggio trasmesso aggiungendo dei blocchi neri in posizioni aleatorie, simulando così un canale rumoroso:



**Figure 2:** Esempio di messaggio "corrotto"



**Figure 4:** A sinistra un canale dove la rete sbaglia, a destra un canale dove la rete non commette errore

La sorgente la cui distribuzione di probabilità è riportata nell'istogramma di sinistra è quello di un "8" che viene erroneamente letto come un "2", che infatti ha entropia  $S = 0.8$ , la sorgente di destra viene invece giustamente letta come un "1", ha entropia  $S = 0.004$

## References

[1] LMP. Calcolo delle probabilità. Zanichelli. 2023:376.

La rete esegue quindi il ciclo di test sulle 9 cifre proposte e corrotte e fornisce i suoi risultati: i numeri che ha letto e l'entropia associata ad ogni canale di trasmissione (per il dettaglio sul calcolo dell'entropia si rimanda a GitHub).

```
Predicted: [0 1 2 8 4 5 6 7 5 4]
Labels:    [0 1 2 3 4 5 6 7 8 9]
entropia di ogni canale (digit): [0.103033595, 0.01410418,
0.24006296, 0.00077312137, 0.42923236, 0.2373108]
Accuracy of the network on the 10 test images: 7 su 10
```

**Figure 3:** Output della rete

Quando una rete di questo tipo deve riconoscere una cifra da come output una distribuzione di probabilità: a ogni possibile numero (da 0 a 9) è associata una probabilità, il numero con la probabilità più alta è il numero che la rete indica come riconosciuto, è quindi facile calcolare l'entropia di Shannon per ogni cifra. Notiamo come la rete commetta un errore in corrispondenza dei canali con entropia più alta, questo perchè l'entropia alta significa che non c'è una probabilità nettamente più alta delle altre, come mostrato dagli istogrammi a lato: